

Université — Cours d'Analyse de Données

Projet de Data Science

Prédiction des résultats de matchs de football

Classification multi-classes appliquée à la Ligue 1

Dépôt	<code>https://github.com/richardghostr/Prediction_match</code>
Données	Ligue 1, saisons 2013–2024 (4 691 matchs)
Livrable	Prédictions saison 2025–2026 (233 matchs)
Notebook	<code>prediction.ipynb</code> — 11 sections

Mai 2026

0. Contents

1	Introduction	2
2	Présentation des données	2
3	Exploration des données (EDA)	2
3.1	Distribution de la variable cible	2
3.2	Évolution par saison	3
3.3	Analyse des buts	3
3.4	Rôle du classement	4
3.5	Valeur marchande et matrice de corrélation	4
4	Prétraitement	4
5	Feature engineering	6
6	Modélisation	6
6.1	Stratégie de validation	6
6.2	Modèles entraînés	7
7	Évaluation des performances	7
7.1	Comparaison des modèles	7
7.2	Matrices de confusion	8
7.3	Importance des variables	8
8	Optimisation du modèle	8
9	Génération des prédictions	9
10	Discussion et limites	10
11	Conclusion	10

1. Introduction

Ce projet vise à prédire le résultat de chaque match de Ligue 1 parmi trois classes : victoire à domicile (1), match nul (0) ou victoire à l'extérieur (-1). Il s'agit d'un problème de *classification multi-classes* traité à partir d'un historique couvrant les saisons 2013 à 2024.

L'ensemble du travail est centralisé dans un notebook Jupyter (`prediction.ipynb`) structuré en onze sections : chargement, exploration, prétraitement, feature engineering, modélisation, évaluation, optimisation et génération des prédictions. L'accent est mis sur la rigueur méthodologique — en particulier sur la qualité du feature engineering et l'absence de fuite de données — plutôt que sur la seule performance brute.

Le livrable final est un fichier `predictions_2025.csv` contenant les prédictions pour 233 matchs de la saison 2025–2026.

2. Présentation des données

Le dossier `data/` regroupe huit fichiers CSV complémentaires, reliés par les clés `game_id`, `club_id` et `player_id`.

Fichier	Contenu	Lignes
<code>matches_2013_2024.csv</code>	Historique des matchs avec résultats	4 691
<code>match_2025.csv</code>	Matchs à prédire (sans résultats)	233
<code>clubs_fr.csv</code>	Métadonnées des clubs	36
<code>player_appearance.csv</code>	Statistiques individuelles par match	128 240
<code>player_valuation_before_season.csv</code>	Valeurs marchandes des joueurs	32 856
<code>game_events_before2025.csv</code>	Événements par minute	61 944
<code>game_lineups.csv</code>	Compositions d'équipes	161 049
<code>sample_results.csv</code>	Format de soumission attendu	233

Table 1: Fichiers de données disponibles dans le dépôt.

La variable cible `results` prend les valeurs 1 (victoire domicile), 0 (nul) et -1 (victoire extérieur). Elle est présente uniquement dans `matches_2013_2024.csv`.

Points de vigilance : les colonnes `home/away_club_formation` et `attendance` contiennent des valeurs manquantes (entre 7 et 8 %) ; les champs monétaires (`net_transfer_record`, `market_value_in_eur`) sont encodés sous forme de chaînes de caractères (€, m, k) et nécessitent une conversion numérique.

3. Exploration des données (EDA)

3.1. Distribution de la variable cible




Figure 1: Distribution des résultats de matchs sur la période 2013-2024 (4 691 matchs).

La classe dominante est la victoire à domicile (44,1 %). Un classifieur naïf qui prédirait systématiquement cette classe atteindrait 44 % d'exactitude : c'est la **baseline** à dépasser. Les matchs nuls (25,9 %) sont la classe la moins représentée, ce qui les rend les plus difficiles à prédire.

3.2. Évolution par saison




Figure 2: Répartition des résultats par saison (2013-2024), en pourcentage.

La répartition est stable dans le temps. On observe une légère augmentation des victoires à l'extérieur sur les dernières saisons, cohérente avec l'évolution tactique du football moderne (pressing haut, jeu de possession des équipes visiteuses).

3.3. Analyse des buts

Les équipes à domicile marquent en moyenne **1,48 buts** contre **1,07** pour les équipes à l'extérieur, confirmant l'avantage du terrain. Les colonnes de buts sont des données de fuite (*data leakage*) : elles ne seront pas utilisées comme variables




Figure 3: Distribution des buts marqués et buts totaux moyens par type de résultat.

explicatives, car elles ne sont pas disponibles avant le coup de sifflet final.

3.4. Rôle du classement




Figure 4: Taux de victoire à domicile en fonction de la position au classement et de l'écart entre les deux équipes.

La position au classement est très discriminante. Quand l'équipe à domicile est bien mieux classée que son adversaire (différence négative), son taux de victoire dépasse 55%. La différence de position (`pos_diff`) constitue donc une feature particulièrement pertinente.

3.5. Valeur marchande et matrice de corrélation

La valeur marchande a fortement augmenté depuis 2013, reflétant l'inflation du marché des transferts. La corrélation entre `home_club_position` et `results` ($r \approx -0.32$) confirme l'utilité de cette variable. La corrélation entre `pos_diff` et `results` ($r \approx -0.35$) justifie la construction d'un différentiel de classement comme feature.

4. Prétraitement

Les étapes de prétraitement sont les suivantes.




Figure 5: Évolution de la valeur marchande médiane des joueurs (gauche) et distribution des valeurs récentes (droite).




Figure 6: Matrice de corrélation des variables numériques des matchs.

Conversion des types. Les colonnes de dates sont converties en `datetime`. Les champs monétaires sont nettoyés et convertis en flottants en euros via la fonction `parse_transfer`.

Agrégation de la valeur marchande. On retient, pour chaque joueur, la dernière valuation connue (sans doublons sur `player_id + current_club_id`), puis on calcule par club : la valeur totale (`total_squad_value`), la valeur moyenne (`avg_player_value`) et la taille de l'effectif valorisé.

Agrégation des statistiques joueurs. Les données de `player_appearance.csv` sont agrégées par (`game_id, player_club_id`), produisant des indicateurs collectifs par équipe et par rencontre : buts, passes décisives, cartons jaunes, cartons rouges, minutes jouées.

Gestion des valeurs manquantes. Un `SimpleImputer` avec stratégie médiane est appliqué avant l'entraînement. Les colonnes `home/away_club_formation` sont exclues de la modélisation.

5. Feature engineering

Le feature engineering est l'étape centrale du projet. Huit familles de variables sont construites, toutes calculées à partir d'informations disponibles *avant* le match.

1. **Forme récente** (5 derniers matchs) : points par match, buts marqués/encaissés, taux de victoires et de nuls, et différentiels dom./ext. Calculé via une boucle temporelle sur les matchs triés par date.
2. **Statistiques dom./ext. de saison** : taux de victoire à domicile, victoire à l'extérieur, moyenne de buts — calculés de façon cumulée jusqu'à la date du match, par saison.
3. **Confrontations directes H2H** : taux de victoires et de nuls sur les 10 derniers matchs entre les deux clubs, avec buts moyens par camp.
4. **Classement et différentiel** : position de chaque club, différence de position (`pos_diff`), ratio, indicateur « top moitié de tableau ».
5. **Statistiques cumulées de saison** : buts marqués/encaissés en moyenne par match depuis le début de la saison, et différentiels entre les deux clubs.
6. **Valeur marchande de l'effectif** : valeur totale et moyenne par club, ratio et différence entre les deux effectifs (`squad_value_ratio`, `squad_value_diff`).
7. **Statistiques joueurs agrégées** : buts, passes décisives et cartons par équipe et par match, issus de `player_appearance.csv`.
8. **Variables structurelles des clubs** : taille de l'effectif, âge moyen, pourcentage d'étrangers, joueurs en sélection nationale, capacité du stade, solde net de transferts.

Les distributions montrent une séparation visible entre les trois classes pour la plupart des features construites. Le différentiel de forme (`form_pts_diff`), le différentiel de classement (`pos_diff`) et le ratio de valeur marchande (`squad_value_ratio`) sont les variables les plus discriminantes.

6. Modélisation

6.1. Stratégie de validation

Un **split temporel** est appliqué : entraînement sur les saisons 2013–2023, test sur la saison 2024. Ce choix est crucial pour éviter toute fuite d'information future dans le jeu d'entraînement. L'ensemble de test contient environ 380 matchs.

Les colonnes susceptibles de créer un data leakage (`home/away_club_goals`, `result_label`, etc.) sont explicitement exclues de la liste de features. Un `LabelEncoder` est appliqué aux identifiants de clubs, et un `SimpleImputer` (médiane) gère les valeurs manquantes




Figure 7: Distribution des six principales features engineerées selon le résultat du match.

résiduelles via un Pipeline scikit-learn.

6.2. Modèles entraînés

Six algorithmes ont été entraînés et comparés : Régression Logistique, Arbre de Décision, Random Forest, Gradient Boosting, XGBoost et LightGBM. Ce choix couvre différentes familles de modèles (modèle linéaire, arbres simples, méthodes d'ensemble par bagging et par boosting), ce qui garantit une comparaison objective.

7. Évaluation des performances

7.1. Comparaison des modèles




Figure 8: Accuracy de chaque modèle sur le jeu de test (saison 2024), comparée à la baseline.

Tous les modèles dépassent la baseline de 44 %. Les méthodes de boosting (XGBoost, LightGBM) obtiennent les meilleures performances. Après optimisation des hyperparamètres par `RandomizedSearchCV`, le LightGBM tuné atteint la meilleure accuracy du benchmark.

7.2. Matrices de confusion




Figure 9: Matrices de confusion des trois meilleurs modèles sur le jeu de test (2024).

L’analyse des matrices de confusion révèle un comportement systématique : les matchs nuls (classe 0) sont sous-prédits par tous les modèles. Ce phénomène est inhérent à la nature du problème — les nuls sont la classe la moins fréquente et la moins prévisible. Les victoires à domicile (classe 1) sont en revanche bien identifiées.

7.3. Importance des variables

Les variables les plus importantes sont, dans l’ordre : le différentiel de classement (`pos_diff`), le différentiel de forme en points (`form_pts_diff`), les buts moyens de la saison (`home_season_gf`), et le ratio de valeur marchande (`squad_value_ratio`). Ces résultats valident les choix de feature engineering effectués.

8. Optimisation du modèle

Validation croisée. Une validation croisée stratifiée à 5 folds (`StratifiedKFold`) est appliquée aux trois meilleurs modèles (Random Forest, LightGBM, Gradient Boosting) pour estimer la stabilité des performances. Les résultats sont présentés sous la forme moyenne $\pm$ écart-type sur les folds.

Optimisation des hyperparamètres. Un `RandomizedSearchCV` avec 40 itérations est appliqué au LightGBM. Les hyperparamètres explorés comprennent `n_estimators`, `learning_rate`, `max_depth`, `num_leaves`, `subsample`, `colsample_bytree` et `min_child_samples`.

Entraînement final. Le meilleur modèle identifié est réentraîné sur la totalité des données historiques (2013–2024) avant de générer les prédictions pour 2025.




Figure 10: Importance des 20 principales variables selon le modèle LightGBM final.

9. Génération des prédictions

Les features pour les 233 matchs de 2025 sont construites en utilisant les données historiques de la saison 2024 comme proxy (positions de fin de saison, statistiques cumulées, valeur marchande, H2H). Le pipeline d'imputation entraîné sur les données historiques est appliqué de façon cohérente aux données de prédiction, sans recalibration.




Figure 11: Distribution des prédictions pour la saison 2025–2026 (gauche) et comparaison avec la distribution historique (droite).

La distribution des prédictions est cohérente avec l'historique observé : la victoire à domicile reste la classe majoritaire. On observe une légère sous-représentation

des nuls dans les prédictions, ce qui reflète la difficulté structurelle à prédire cette classe.

10. Discussion et limites

Points forts. La démarche est complète et rigoureuse : split temporel, exclusion explicite des variables de fuite, feature engineering motivé par le domaine, comparaison de plusieurs familles de modèles et optimisation des hyperparamètres. Les features construites ont un pouvoir discriminant avéré (cf. figures des distributions et de l'importance).

Limites inhérentes au problème. La prédiction de résultats de football est contrainte par la nature aléatoire du sport. Même les meilleures approches atteignent rarement plus de 55–60 % d'exactitude sur ce type de problème — un plafond qui n'est pas le reflet de la qualité du modèle mais de l'imprévisibilité du jeu.

Données indisponibles. Plusieurs informations potentiellement utiles ne sont pas accessibles : statistiques avancées (xG, possession, tirs), blessures et suspensions, conditions météorologiques, calendrier inter-compétitions. Les compositions exactes pour les matchs de 2025 sont inconnues, ce qui limite la précision des features basées sur les titularisations.

Classe nul. Les matchs nuls sont systématiquement sous-prédits, ce qui est cohérent avec leur rareté relative et leur imprévisibilité. Des techniques spécifiques (suréchantillonnage, pondération des classes, seuillage des probabilités) pourraient partiellement atténuer ce biais.

11. Conclusion

Ce projet illustre une démarche complète de data science appliquée à la prédiction de résultats de football. Le feature engineering — en particulier les indicateurs de forme récente, le différentiel de classement, l'historique des confrontations directes et la valeur marchande des effectifs — constitue la contribution principale. Le modèle LightGBM, après optimisation des hyperparamètres, dépasse significativement la baseline naïve de 44 % et produit des prédictions cohérentes avec la distribution historique des résultats.

Les pistes d'amélioration identifiées comprennent l'intégration de données avancées (xG, possession), l'utilisation de modèles de séries temporelles (LSTM, Temporal Fusion Transformer), la calibration probabiliste pour produire des estimations fiables de probabilité, et l'apprentissage par ensemble pour combiner les meilleurs modèles.